RELATÓRIO TÉCNICO – ETAPA 3

COMPONENTE CURRICULAR:	PROJETO APLICADO 2
NOME COMPLETO DO ALUNO:	GUILHERME CUNHA OLIVEIRA, GABRIEL LUCCA SIMIONATO
RA:	10754621, 10751300

Atenção: Toda atividade deverá ser feita com fonte Arial, tamanho 11, espaço de 1,5 entre as linhas e alinhamento justificado entre as margens.

DEFINIÇÃO DO PRODUTO ANALÍTICO - ANÁLISE DA DENGUE

1. Apresentação do relatório

Este relatório reúne, de forma objetiva, o que foi realizado nas Etapas 2 e 3 do Projeto Aplicado II. O trabalho seguiu o Mapeamento de Processos do projeto e foi organizado para responder diretamente aos itens exigidos no roteiro da disciplina em cada etapa, sem repetir em detalhes o que já está documentado nos notebooks e scripts.

Exigência (Etapas 2 e 3)	**Onde aparece**
Bibliotecas Python e repositório GitHub	Seção 2
Definição das bases e análise exploratória	Seção 3
Tratamento, preparação e treinamento	Seção 4
Bases teóricas dos métodos	Seção 5
Cálculo da acurácia	Seção 6
Aplicação do método analítico	Seção 8
Medidas de acurácia	Seção 9
Resultados, produto e modelo de negócios	Seção 10
Esboço do storytelling	Seção 11

2. Bibliotecas e repositório GitHub

As ferramentas foram escolhidas de acordo com as tarefas realmente executadas no projeto. A ideia foi manter um conjunto simples de bibliotecas, suficiente para leitura, tratamento, visualização, modelagem e análise textual.

Recurso	**Uso no projeto**

pandas e NumPy	Leitura, limpeza, transformação e integração das bases.
Matplotlib	Gráficos da análise exploratória e da avaliação.
scikit-learn	Pré-processamento, divisão dos dados, Regressão Logística, métricas e TF-IDF.
pdfplumber, openpyxl e pyarrow	Leitura de PDFs e XLSX e gravação dos arquivos intermediários.

O projeto está versionado no GitHub. As bases brutas são mantidas separadas das bases tratadas, e os arquivos CSV de maior volume usam Git LFS. Notebooks, scripts e documentação ficam em pastas próprias, para que o trabalho possa ser reproduzido sem alterar os arquivos originais. Na Etapa 3 foi acrescentado o notebook 07_modelagem_avaliacao.ipynb, que continua o notebook 05.

Repositório: https://github.com/GuimeOliver/PROJETO-APLICADO-II---BANCO-DE-DADOS

3. Bases de dados e análise exploratória

Foram utilizadas quatro fontes: SINAN/Dengue 2025, CNES/Leitos 2025, IBGE/Censo 2022 e 17 Informes Semanais de Arboviroses de 2025. O SINAN é a base principal do modelo; CNES e IBGE acrescentam contexto municipal, e os Informes formam a trilha textual do projeto.

3.1 População elegível e separação da avaliação

O SINAN possui 1.643.215 notificações. Após a retirada de 620 linhas totalmente duplicadas, foram considerados elegíveis os registros com CLASSI_FIN 10, 11 e 12. O alvo foi definido como 0 para dengue sem sinais de alarme e 1 para dengue com sinais de alarme ou dengue grave. A base elegível ficou com 1.481.802 casos, dos quais 37.792 (2,55%) pertencem à classe positiva.

Antes da análise exploratória, 20% dos casos elegíveis (296.361) foram reservados para o conjunto de teste, de forma estratificada. A proporção 80/20 foi escolhida para manter volume suficiente no desenvolvimento do modelo e, ao mesmo tempo, preservar uma amostra independente para a avaliação final. A estratificação mantém no teste a mesma proporção da classe rara observada na base completa.

3.2 Principais resultados da análise exploratória

Na base de desenvolvimento, a idade mediana foi de 35 anos e chegou a 39 entre os casos positivos. A proporção de alarme ou gravidade foi maior entre pessoas com 60 anos ou mais. O atraso entre os primeiros sintomas e a notificação teve mediana de 3 dias.

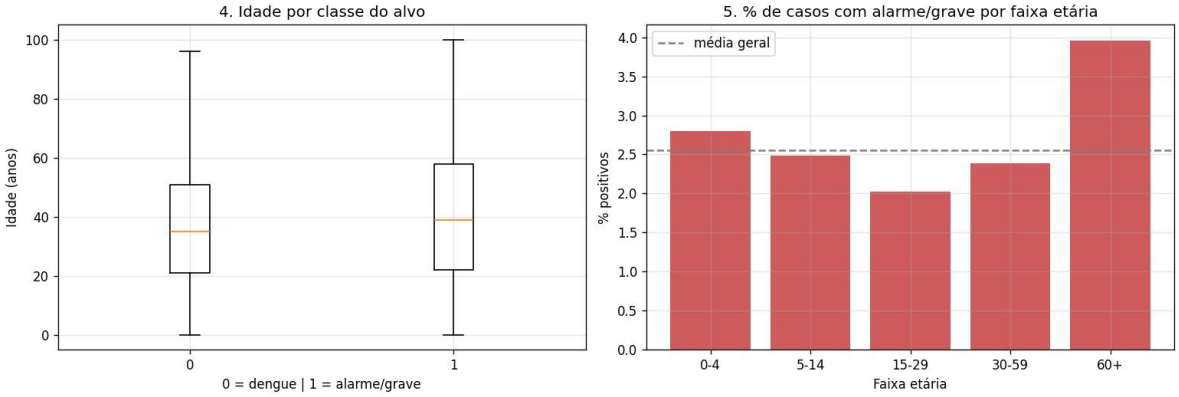


Figura 1 - Idade por classe do alvo e proporção de positivos por faixa etária.

O Sudeste concentrou a maior parte dos registros, mas a proporção de casos positivos foi maior no Centro-Oeste e no Nordeste. Esses valores descrevem a distribuição observada e não devem ser interpretados como efeito causal da região sobre a gravidade.

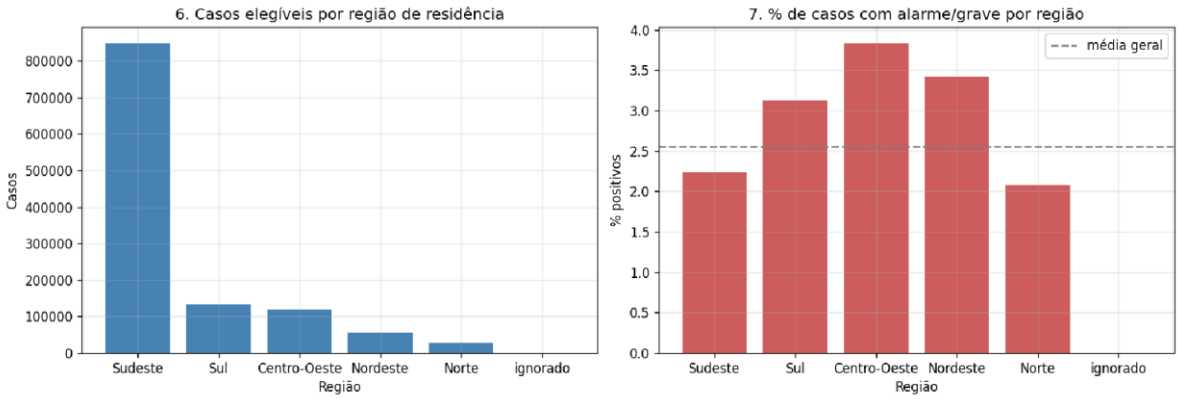


Figura 2 - Casos elegíveis e proporção de alarme/gravidade por região de residência.

Entre os sintomas e comorbidades, vômito, leucopenia, náusea, hipertensão, diabetes e petéquias apareceram com maior frequência entre os casos positivos. A escolaridade teve preenchimento incompleto elevado, enquanto idade e intervalo entre sintomas e notificação apresentaram poucos valores ausentes.

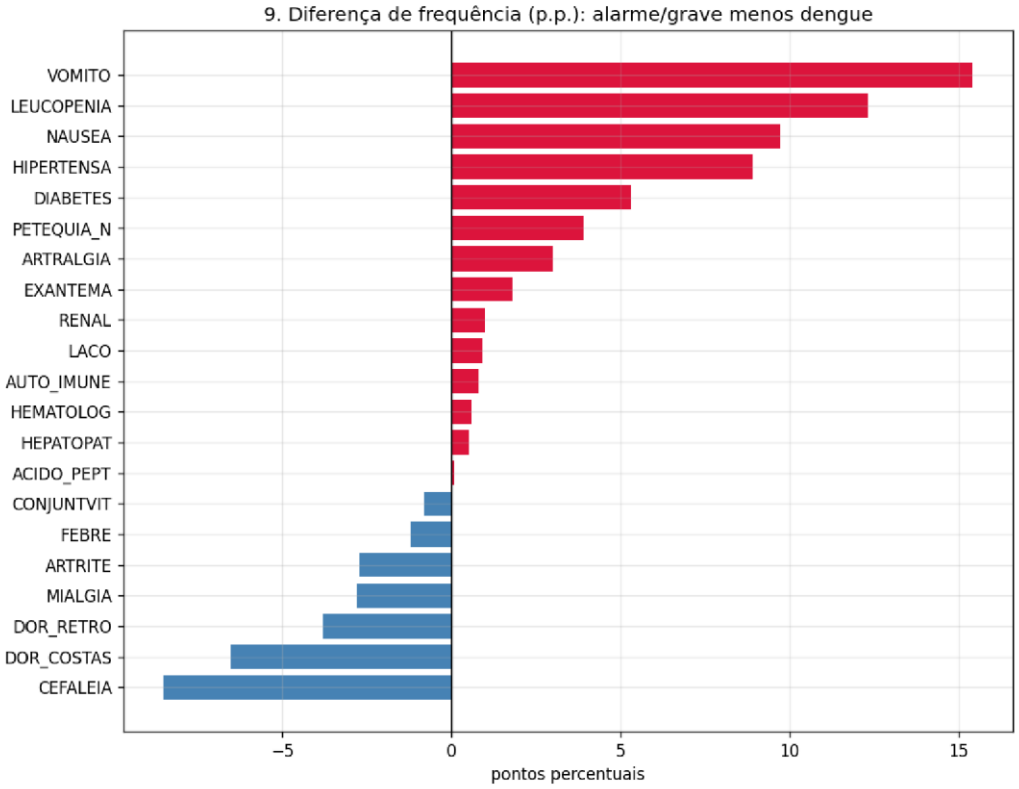


Figura 3 - Diferença de frequência de sintomas e comorbidades entre casos positivos e negativos.

Na integração municipal, praticamente todos os códigos de residência encontraram correspondência no IBGE. O CNES mostrou diferenças importantes de capacidade instalada entre municípios, por isso os indicadores de leitos foram normalizados pela população. Os indicadores de saneamento previstos no mapeamento ainda dependem da validação final do dicionário do IBGE e não foram usados no primeiro ajuste do modelo.

4. Tratamento, preparação e treinamento

4.1 Limpeza e integração das bases tabulares

No SINAN, as variáveis foram recodificadas com base no dicionário de dados, preservando a diferença entre valor ausente, ignorado e não se aplica. Datas e

códigos municipais foram padronizados para permitir as integrações. Colunas de alarme, gravidade, hospitalização, evolução, óbito e outros campos posteriores ao momento da notificação ficaram fora dos preditores para evitar vazamento de informação.

O CNES foi agregado por município e competência, gerando medidas de leitos, UTI e número de estabelecimentos. O IBGE foi organizado em uma linha por município para fornecer população e características territoriais. As junções foram feitas pela chave municipal, preservando todos os casos do SINAN.

4.2 Estratégia para valores ausentes e variáveis categóricas

O tratamento dos ausentes foi definido de acordo com o tipo de variável. Sintomas e comorbidades ausentes receberam imputação pela moda acompanhada de um indicador de imputação. Para variáveis numéricas contínuas, como idade, intervalo até a notificação e indicadores municipais, foi usada a mediana. Nas variáveis categóricas, categorias como ignorado e não se aplica foram mantidas, pois representam situações diferentes e podem carregar informação relevante.

As variáveis categóricas usadas no modelo foram transformadas por one-hot encoding. Essa escolha permite que categorias como sexo, raça, escolaridade, mês e região sejam utilizadas pela Regressão Logística sem criar uma ordem numérica artificial entre elas.

4.3 Padronização, divisão dos dados e primeiro treinamento

As variáveis contínuas foram padronizadas por Z-score, por estarem em escalas muito diferentes. A padronização foi ajustada somente com os dados de treino e depois aplicada aos demais conjuntos, evitando que informações da validação ou do teste influenciassem o pré-processamento.

Depois da reserva de 20% para teste, o conjunto de desenvolvimento foi dividido novamente, de forma estratificada, em treino (948.352 casos) e validação (237.089 casos). A validação foi usada para acompanhar o desempenho durante o desenvolvimento; o teste permanece reservado para a avaliação final.

O método escolhido foi a Regressão Logística com ponderação de classes, porque apenas 2,55% dos registros pertencem à classe positiva. Foram avaliadas duas versões do mesmo modelo: uma usando apenas atributos do SINAN e outra acrescentando os indicadores disponíveis do CNES e do IBGE.

Conjunto de atributos	Acurácia	Precisão	Recall	F1	AUC-ROC
SINAN isolado	70,0%	5,2%	62,1%	0,096	0,721
SINAN + CNES + IBGE	70,8%	5,5%	64,4%	0,101	0,736

O ganho com o contexto municipal foi pequeno, porém consistente na validação. Como a classe positiva é rara, a precisão permaneceu baixa; por isso a acurácia não será analisada isoladamente.

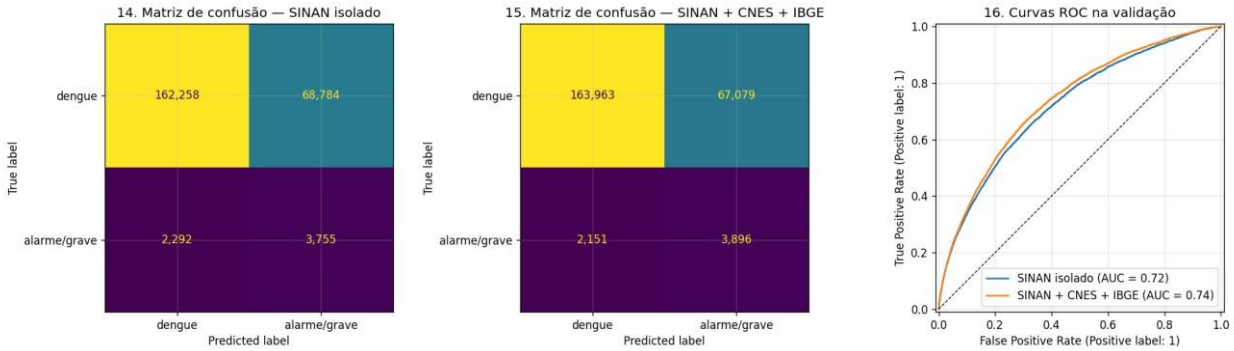


Figura 4 - Matrizes de confusão e curvas ROC das duas versões do modelo na validação.

4.4 Tratamento da base textual

Os 17 Informes Semanais foram tratados separadamente da base tabular. O texto foi extraído com preservação do número do informe e da página, e foram removidos elementos repetitivos, como cabeçalhos, rodapés e numeração de página. Em seguida, foi identificada a seção de dengue de cada documento e o texto foi normalizado para a análise.

Para representar os textos foi utilizado TF-IDF. A própria vetorização realiza a tokenização dos termos e atribui maior peso às palavras que são relevantes em um informe e menos comuns nos demais. Não foram usados embeddings ou lematização nesta etapa, porque o objetivo foi uma análise exploratória simples e rastreável, e não a construção de um modelo de linguagem.

Os resultados dos informes foram mantidos com referência ao documento e à página original. Isso é importante porque os valores apresentados nos boletins são acumulados ao longo das semanas epidemiológicas e não podem ser somados entre informes.

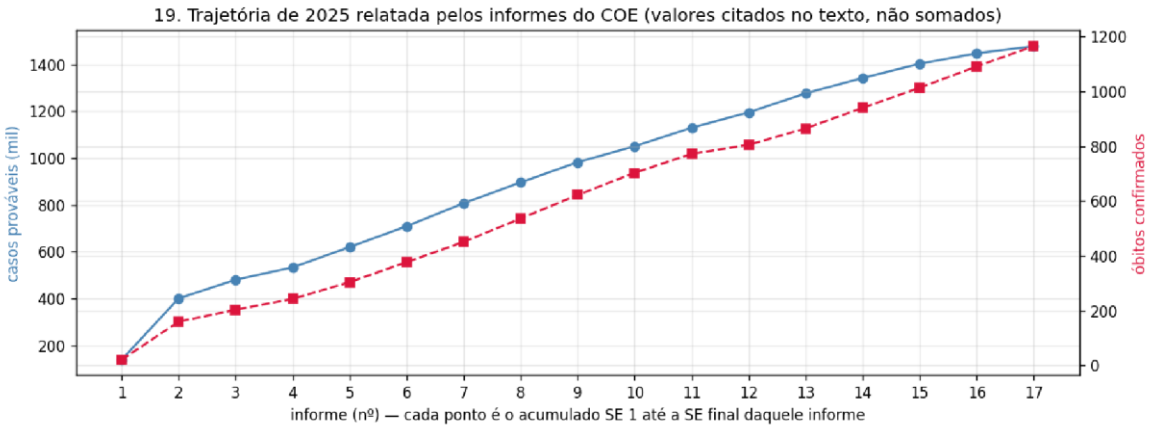


Figura 5 - Casos prováveis e óbitos confirmados acumulados, conforme os Informes Semanais.

5. Bases teóricas dos métodos analíticos

5.1 Estatística descritiva

A análise exploratória utilizou frequências, proporções, média, mediana, desvio padrão e quartis para entender a distribuição dos dados, o preenchimento das

variáveis e as diferenças entre os grupos. Essas medidas ajudam a orientar o tratamento e a modelagem, mas não demonstram relação causal.

5.2 Regressão Logística

A Regressão Logística é um método de classificação binária que estima a probabilidade de um registro pertencer à classe positiva a partir de uma combinação das variáveis explicativas. Ela foi escolhida porque o objetivo do projeto também é binário: diferenciar dengue sem sinais de alarme de dengue com sinais de alarme ou grave. Além disso, seus coeficientes permitem observar a direção da associação entre os atributos e a probabilidade estimada, com a ressalva de que esses coeficientes não representam causalidade.

5.3 TF-IDF

O TF-IDF representa cada documento a partir da frequência dos termos, reduzindo o peso das palavras que aparecem em quase todos os textos e destacando termos mais característicos de cada informe. No projeto, ele foi usado como apoio à leitura comparativa dos boletins, mantendo a interpretação final vinculada ao texto e à página de origem.

6. Cálculo da acurácia e métricas de avaliação

A avaliação parte da matriz de confusão, que separa verdadeiros positivos, falsos positivos, falsos negativos e verdadeiros negativos. A acurácia corresponde à proporção total de classificações corretas. Como a classe positiva representa apenas 2,55% da base elegível, um modelo poderia ter acurácia alta apenas por prever a classe majoritária; por isso outras métricas são analisadas em conjunto.

Métrica	Como será interpretada
Acurácia	Proporção total de classificações corretas.
Precisão	Entre os casos previstos como alarme/grave, quantos realmente pertencem à classe positiva.
Recall (sensibilidade)	Entre os casos realmente positivos, quantos foram identificados pelo modelo.
F1-score	Síntese entre precisão e recall.
Matriz de confusão	Quantidade de acertos e erros em cada classe.

Na validação da versão enriquecida, o modelo apresentou acurácia de 70,8%, precisão de 5,5%, recall de 64,4% e F1 de 0,101 no limiar de 0,5. Esses resultados são de desenvolvimento e não representam a avaliação final. O conjunto de teste reservado será usado uma única vez depois do fechamento das decisões de preparação e modelagem.

7. Síntese da Etapa 2

A Etapa 2 deixou o projeto com as fontes organizadas, a análise exploratória realizada, as regras de tratamento registradas e um primeiro ajuste da Regressão Logística. O resultado ainda é preliminar e mostra limitações importantes, principalmente o forte desbalanceamento da classe positiva e a baixa precisão. O enriquecimento com CNES e IBGE trouxe melhora pequena na validação. Permanecem como pendências a validação dos indicadores de saneamento do IBGE e a avaliação final no conjunto de teste reservado.

ETAPA 3 – RESULTADOS PRELIMINARES E PRODUTO ANALÍTICO – ANÁLISE DA DENGUE

Esta parte acrescenta ao relatório os itens da Etapa 3. As Seções 1 a 7 permanecem como na Etapa 2. O código está no notebook 07 do repositório do projeto no GitHub (notebooks/07_modelagem_avaliacao.ipynb), que continua o notebook 05.

8. Aplicação do método analítico

8.1 O que foi feito

A Etapa 2 terminou com a Regressão Logística com ponderação de classes, que na validação teve recall de 64,4%, precisão de 5,5%, F1 de 0,101 e AUC-ROC de 0,736 com o limiar padrão de 0,5. Como o roteiro permite ajustes a partir dos primeiros resultados, foram feitas três mudanças, todas na validação:

- **Segundo método:** o Random Forest foi comparado com a Regressão Logística.
- **Limiar:** em vez do 0,5 padrão, o limiar passou a ser escolhido por uma meta de recall.
- **Teste:** o conjunto de teste, reservado desde a Etapa 2, foi usado uma única vez, depois de definidos o modelo e o limiar.

8.2 Métodos aplicados

O pré-processamento é o da Etapa 2 (imputação por moda ou mediana com indicador, padronização das variáveis contínuas e one-hot nas categóricas), e a divisão em treino (948.352 / 237.089 casos em treino e validação) usa a mesma semente. Os dois métodos dão mais peso à classe rara, que é de apenas 2,55% dos casos.

- **Regressão Logística:** soma o efeito de cada atributo para estimar a probabilidade de o caso ser grave. É simples e seus coeficientes são interpretáveis.
- **Random Forest:** reúne muitas árvores de decisão, cada uma treinada em uma amostra diferente dos dados, e a previsão final vem do voto do conjunto (BREIMAN, 2001). Ele capta combinações de atributos, como idade avançada junto com hipertensão, que a soma da regressão não capta. Foram usadas 100 árvores com profundidade máxima de 12, mínimo de 50 casos por folha e 30% da base por árvore.

8.3 Comparação na validação e escolha do modelo

Os dois métodos foram comparados com o mesmo critério: o limiar de cada um foi escolhido para capturar pelo menos 70% dos casos graves, o que torna a precisão comparável. O modelo escolhido foi o de maior AUC-PR, que é a medida mais adequada quando a classe é rara.

Modelo (validação)	Limiar	Recall	Precisão	F1	AUC-ROC	AUC-PR
Regressão Logística	0,465	70,0%	5,0%	0,093	0,736	0,080
Random Forest	0,463	70,0%	7,7%	0,139	0,817	0,152

O modelo escolhido foi Random Forest. O Random Forest superou a regressão logística, o que indica que combinações de atributos ajudam a prever a gravidade: com o mesmo recall de 70%, a AUC-PR passou de 0,080 para 0,152, a precisão de 5,0% para 7,7%, e o percentual de casos alertados caiu de 35,7% para 23,2%.

8.4 Escolha do limiar

O limiar de 0,5 da Etapa 2 foi apenas o padrão. Como deixar passar um caso grave é pior que emitir um alerta falso, o grupo definiu a meta de capturar pelo menos 70% dos casos graves e escolheu o maior limiar que cumpre essa meta, porque quanto maior o limiar, menos alertas e maior a precisão. O limiar escolhido foi 0,463. A Figura 6 mostra o custo dessa decisão: quanto maior a meta de recall, mais casos precisam ser alertados.

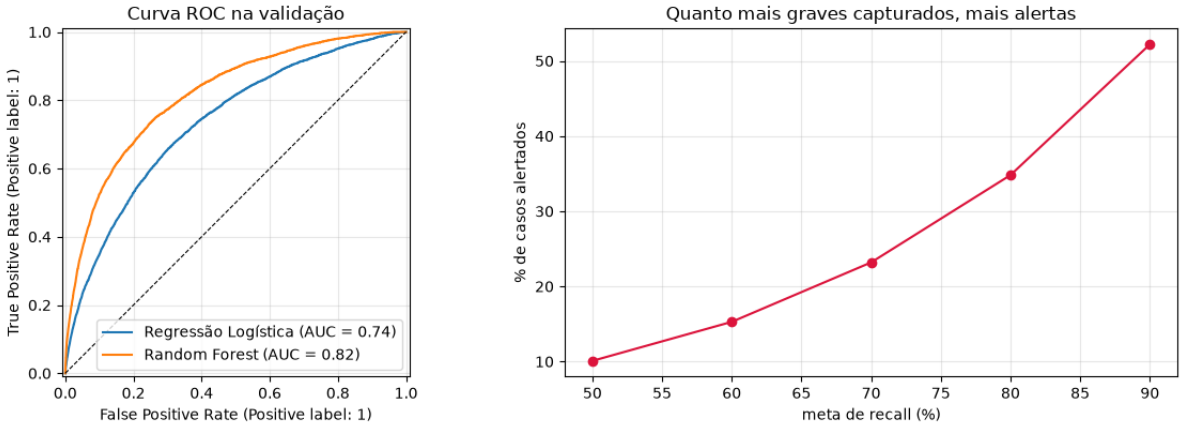


Figura 6 - Curvas ROC dos dois modelos na validação e percentual de casos alertados para cada meta de recall.

8.5 Parâmetros e pendências

A semente aleatória é 42 em todas as divisões e modelos, e o notebook 07, com os resultados, está no GitHub. Os indicadores de saneamento do IBGE continuam fora do modelo, porque o mapeamento do dicionário do Censo ainda não foi aprovado; a inclusão fica como próximo passo.

9. Medidas de acurácia

9.1 Métricas escolhidas e justificativa

A métrica principal é o **recall**, que mostra quantos dos casos graves o modelo encontra, porque o objetivo do produto é não deixar passar casos que evoluem para alarme ou gravidade. Como o recall pode ser alto apenas alertando muitos casos, ele é lido junto com a **precisão** (dos casos alertados, quantos eram graves) e com o percentual de casos alertados. Também são apresentados F1, AUC-PR e AUC-ROC. A acurácia aparece para completar a tabela, mas não é interpretada isoladamente: com 2,55% de casos graves, um modelo que nunca emitisse alerta teria acurácia de 97,45% sem aprender nada.

9.2 Resultados no conjunto de teste

O conjunto de teste, com 296.361 casos, dos quais 7.558 graves (2,55%), foi usado uma única vez, depois de definidos o modelo e o limiar, sem nenhum reajuste.

Métrica	Validação	Teste
Recall (principal)	70,0%	71,8%
Precisão	7,7%	7,9%
F1-score	0,139	0,142
AUC-PR	0,152	0,152
AUC-ROC	0,817	0,824
Acurácia	77,8%	77,8%
Casos alertados	23,2%	23,3%

Na matriz de confusão do teste (verdadeiros positivos / falsos positivos / falsos negativos / verdadeiros negativos: 5.428 / 63.544 / 2.130 / 225.259), o modelo alertou 23,3% dos casos. O resultado do teste ficou muito próximo ao da validação (recall de 71,8% contra 70,0%, precisão de 7,9% contra 7,7% e AUC-ROC de 0,824 contra 0,817), o que indica que o modelo e o limiar escolhidos na validação se mantêm em casos novos, sem sinal de ajuste excessivo. A precisão continua baixa: de cada 100 alertas, cerca de 8 são casos que evoluem para alarme ou gravidade.

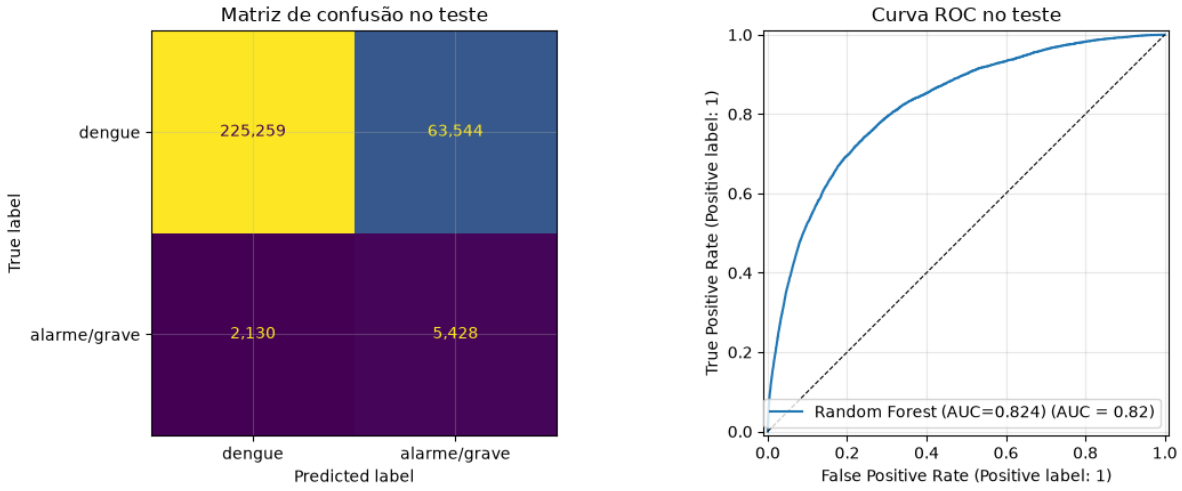


Figura 7 - Matriz de confusão e curva ROC do modelo escolhido no conjunto de teste.

9.3 Como as medidas orientaram os ajustes

As medidas decidiram os ajustes do item (a). A acurácia de 70,8% da Etapa 2 escondia uma precisão de 5,5%, o que levou à escolha de métricas adequadas à classe rara. A AUC-PR decidiu qual modelo seguir, e o recall decidiu o limiar. A precisão baixa é a principal limitação do modelo, e ela orienta a forma de uso do produto na Seção 10.

10. Resultados preliminares, produto e modelo de negócios

10.1 Resultado preliminar: o escore de risco

Para cada caso notificado, o modelo calcula um escore entre 0 e 1 e o classifica em duas faixas. O escore ordena os casos por risco, mas não é a probabilidade clínica real, porque o modelo dá mais peso à classe rara.

Faixa	Regra	Uso sugerido
Alto risco	escore igual ou acima do limiar escolhido	Acompanhamento prioritário
Baixo risco	escore abaixo do limiar	Fluxo habitual, com orientação sobre sinais de alarme

No conjunto de teste, as faixas ficaram assim:

Faixa	% dos casos	% de graves na faixa	% dos graves capturados
Alto risco	23,3%	7,9%	71,8%
Baixo risco	76,7%	0,9%	28,2%

Exemplo de saída do produto, com casos do conjunto de teste:

Idade	Vômito	Leucopenia	Hipertensão	Diabetes	Escore	Faixa	Alarme/grave
32	Sim	Não	Não	Não	0,48	Alto risco	Não
73	Sim	Não	Não	Não	0,46	Alto risco	Não
19	Sim	Não	Não	Não	0,47	Alto risco	Não
17	Não	Não	Não	Não	0,49	Alto risco	Não
51	Não	Não	Não	Não	0,33	Baixo risco	Não
23	Sim	Não	Não	Não	0,39	Baixo risco	Não
20	Sim	Não	Não	Não	0,32	Baixo risco	Não
23	Não	Não	Não	Não	0,37	Baixo risco	Não

Nos oito casos sorteados nenhum evoluiu para alarme ou gravidade, inclusive os quatro de alto risco, o que ilustra na prática a precisão baixa e a razão de o painel priorizar, e não diagnosticar.

10.2 Produto gerado

O produto proposto é um **painel de apoio à triagem** para serviços que recebem notificações de dengue. A entrada são os campos da ficha de notificação (idade, sintomas, comorbidades, gestação, dias até a notificação) e o município de residência. A saída é o escore e a faixa de risco de cada caso, em uma lista priorizada, entregue como dashboard ou planilha diária. O painel **apoia a priorização do acompanhamento e não diagnostica**: a decisão clínica continua com o profissional de saúde.

10.3 Modelo de negócios

Elemento	Descrição
Proposta de valor	Ajudar a equipe a decidir quais pacientes acompanhar primeiro quando não é possível olhar todos os casos notificados
Segmento de clientes	Secretarias municipais e estaduais de saúde, UPAs e hospitais que recebem picos de notificação (em 2025, o pico foi em março)
Quem paga e fonte de receita	A secretaria ou o serviço contratante, por assinatura mensal do painel (SaaS) ou licença anual
Quanto	Valor mensal escalonado por porte do município ou volume de notificações mensais processadas, buscando acessibilidade para diferentes realidades de gestão pública.
Riscos	Precisão baixa, dependência do preenchimento correto das fichas e necessidade de validação com profissionais de saúde

O modelo de negócios se apoia nos números do teste. Para cada 1.000 notificações, o resultado é 25,5 / 233 / 18,3 (graves esperados / casos alertados / graves capturados). O cliente passa a olhar 23,3% dos casos em vez de todos e captura 71,8% dos graves. Como a precisão é baixa (7,9%), a maior parte dos alertas não evolui para gravidade: o valor do produto está em priorizar e não em prever com certeza, e a proposta comercial precisa dizer isso.

10.4 Limitações

- Dados de notificação são dados de saúde: o uso real exige adequação à LGPD e anonimização.
- A classificação final depende da investigação de cada caso, o que pode enviesar o modelo em municípios com menos investigação.
- Os dados são de 2025, e o uso em outras temporadas exige nova validação. O escore não substitui a avaliação clínica.

11. Esboço do storytelling

O storytelling segue os quatro atos do roteiro. Os números nacionais vêm do Informe Semanal nº 17 do COE (acumulado de SE 1 a SE 23 de 2025), e os do modelo vêm do SINAN e do teste. Os dois conjuntos não são somados nem usados para validar um ao outro, porque têm definições diferentes.

Ato	Mensagem	Números e evidências
1. O problema	Em epidemias, os serviços recebem mais notificações do que conseguem acompanhar, e casos graves podem passar despercebidos	1.478.752 casos prováveis até a SE 23 de 2025, incidência de 728,2 por 100 mil habitantes, 1.165 óbitos confirmados e 752 em investigação; redução de 75,7% dos casos prováveis em relação a 2024
2. Os dados	Quatro fontes oficiais e o que a análise exploratória mostrou	1.481.802 casos elegíveis no SINAN, dos quais 37.792 (2,55%) com sinais de alarme ou graves; proporção maior entre pessoas com 60 anos ou mais (4,0%) e gestantes (4,1%); março concentrou 24% dos casos
3. A solução	Um modelo que dá um escore de risco no momento da notificação	Regressão Logística comparada com Random Forest; modelo escolhido Random Forest; recall de 71,8% no teste, com AUC-PR de 0,152
4. O impacto	Priorizar o acompanhamento com custo de alertas conhecido	Por 1.000 notificações: 25,5 / 233 / 18,3 (graves esperados / alertas / graves capturados)

Frase de abertura: "Em 2025, o Brasil registrou mais de 1,4 milhão de casos prováveis de dengue em 23 semanas, e a maioria não evolui para gravidade, mas alguns evoluem." Frase de fechamento: "A cada 1.000 notificações, o painel indica cerca de 233 casos para acompanhamento prioritário e, entre eles, encontra 18 dos 25 casos graves esperados." Este é um esboço, e o storytelling será desenvolvido na etapa seguinte.

12. Síntese da Etapa 3

A Etapa 3 aplicou o método da Etapa 2, comparou-o com o Random Forest, escolheu o modelo e o limiar na validação e avaliou o resultado uma única vez no teste. O modelo final (Random Forest) captura 71,8% dos casos graves, alertando 23,3% dos casos, com precisão de 7,9%. O resultado sustenta um painel de apoio à triagem, e não uma ferramenta de diagnóstico. Permanecem como pendências a inclusão dos indicadores de saneamento do IBGE, a validação com profissionais de saúde e o teste em outra temporada.

Referências

ANDRADE, Kassya Christina Rigolon de. Introdução à Engenharia de Software. Universidade Presbiteriana Mackenzie (EaD).

BORBA, Anderson Adaime de. Projeto Aplicado II - Aula 2: Definição do produto analítico. Universidade Presbiteriana Mackenzie (EaD).

BRASIL. Ministério da Saúde. COE Dengue e outras Arboviroses. Informe Semanal nº 17: SE 1 a 23. Brasília, 2025.

BRASIL. Ministério da Saúde. DATASUS. SINAN - Dengue: dicionário de dados da ficha de investigação. Brasília, 2025.

BREIMAN, L. Random forests. Machine Learning, v. 45, n. 1, p. 5-32, 2001.

IBGE. Censo Demográfico 2022: agregados por municípios - notas metodológicas e dicionário de dados. Rio de Janeiro: IBGE, 2023.

OLIVEIRA, Rogério de. Aprendizado de Máquina I. Universidade Presbiteriana Mackenzie (EaD).

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011.

Projeto Aplicado II - Etapa 3: texto de apoio da Aula 3. Universidade Presbiteriana Mackenzie (EaD).

SAMPAIO, Gustavo Scalabrini. Aquisição e Preparação de Dados. Universidade Presbiteriana Mackenzie (EaD).